

Universidad Industrial de Santander

Asignatura: Simulación Digital

Simulación de una Cadena Logística Inteligente basada en Datos IoT

Avance 1 y 2

Integrantes del Grupo:

Harold Esteban Duran Osma – 2225113
Luige Alejandro Velazco Hurtado – 2225226
Yerson Guillermo Antolinez Peña – 2225611

Presentado a:

Prof. David Romo Bucheli, PhD

4 de mayo de 2026

1. Formulación del Problema

Un centro de distribución logística inteligente recibe un volumen variable de pedidos a lo largo del día, los cuales deben ser asignados a una flota de camiones para su posterior entrega. El sistema opera actualmente con una flota fija de 10 camiones, los cuales pueden encontrarse en estado disponible, en tránsito, o en mantenimiento. Cada pedido ingresa al sistema y se le asocia un envío que, dependiendo de la dinámica de la operación, puede ser entregado a tiempo, encontrarse en ruta, o sufrir retrasos.

Las condiciones operativas de este centro de distribución no son estáticas; están fuertemente influenciadas por múltiples factores de naturaleza estocástica. Entre los factores más críticos se encuentran las condiciones de tráfico en la ciudad, las cuales afectan directamente los tiempos de tránsito de los vehículos. Asimismo, las condiciones ambientales, como la temperatura y la humedad, imponen restricciones operativas severas, ya que ciertos productos sensibles requieren vehículos con climatización adecuada; si estas condiciones no se cumplen, las entregas pueden invalidarse. Finalmente, la cantidad de productos en inventario y los picos repentinos de demanda generan cuellos de botella temporales.

El problema central radica en que la configuración empírica actual de asignación de pedidos a los camiones no responde eficientemente a la variabilidad del sistema. Ante picos de demanda y condiciones de tráfico adversas, los pedidos experimentan altos tiempos de espera en cola antes de ser asignados a un vehículo, lo que deriva en una alta tasa de retrasos logísticos y un uso desequilibrado de la flota de transporte. Se hace necesario evaluar esta dinámica para proponer una configuración que garantice entregas oportunas sin sobredimensionar la cantidad de activos.

2. Objetivos del estudio de simulación

Para el presente estudio, las cantidades de interés principales del sistema son: el **tiempo de espera en cola** de los pedidos antes de ser despachados, la **probabilidad de retraso logístico** en las entregas, y el **porcentaje de utilización de la flota** de camiones.

Objetivo General

Evaluar, mediante la simulación de eventos discretos, el comportamiento del sistema de asignación de pedidos de un centro de distribución logística para identificar la configuración óptima de camiones y políticas de despacho que minimicen los retrasos y reduzcan los tiempos de espera.

Objetivos Específicos

- **Caracterizar** las distribuciones estadísticas de las tasas de llegada de pedidos, los tiempos de servicio influenciados por el tráfico, y las restricciones climáticas operativas.
- **Estimar** el desempeño del sistema bajo la configuración actual (10 camiones y asignación por orden de llegada) en términos de la cantidad de interés de tiempo promedio de espera y utilización de la flota.
- **Comparar** el impacto de implementar políticas de asignación alternativas frente a escenarios de alto estrés, como picos de demanda y congestión vehicular extrema.
- **Optimizar** el número mínimo de camiones activos necesarios por turno para garantizar que el tiempo de espera no supere el umbral histórico de tolerancia aceptable.

3. Plan general del proyecto

3.1. Justificación del proyecto y del uso de simulación

Las cadenas logísticas modernas enfrentan un entorno de alta incertidumbre. La gestión basada en reglas fijas resulta insuficiente ante la congestión vehicular impredecible y la variabilidad de la demanda en tiempo real.

El sistema bajo estudio presenta características que hacen inviable una solución analítica mediante teoría de colas tradicional: posee tasas de llegada no estacionarias (fluctúan según la hora del día), múltiples estados para los recursos, condiciones externas aleatorias que modifican los tiempos de servicio y un comportamiento de cola finita donde la demora excesiva se penaliza directamente como un retraso logístico. Por lo tanto, una simulación computacional de eventos discretos es la herramienta idónea. Permite reproducir fielmente esta dinámica estocástica y probar distintas configuraciones sin interrumpir la operación real, obteniendo estimaciones estadísticamente robustas.

3.2. Fuentes de Datos y Mapeo de Variables

Para la construcción y validación del modelo se utilizará el *Smart Logistics Supply Chain Dataset* (obtenido de Kaggle), el cual cuenta con 1000 registros históricos detallados. A partir de este punto del documento, los conceptos del sistema se modelarán según las variables técnicas extraídas de este dataset, como se detalla en la siguiente tabla:

Tabla 1: Mapeo de conceptos del sistema a variables del modelo

Concepto del Sistema	Variable Técnica	Uso en el modelo
Llegadas por hora de pedidos	Timestamp	Cálculo de la tasa de llegadas (λ)
Flota de camiones	Asset_ID	Recurso de la simulación
Tiempo de espera en cola	Waiting_Time	Cantidad de interés (W_q)
Utilización de flota	Asset_Utilization	Cantidad de interés (ρ)
Niveles de congestión	Traffic_Status	Factor de penalización en tiempo de servicio
Clima (Restricciones)	Temperature, Humidity	Condicionantes para asignación de envíos
Retraso logístico	Logistics_Delay	Variable objetivo a minimizar ($P(\text{Delay})$)

Reafirmación técnica del objetivo de optimización: Con base en estas variables, el propósito final del estudio es encontrar el número de camiones c tal que el tiempo de espera cumpla con $W_q \leq$ percentil 80 histórico y que la probabilidad de retraso sea $P(\text{Delay}) \leq 10\%$.

3.3. Sistemas Alternativos a Evaluar (Escenarios)

Se probarán diferentes configuraciones para analizar la robustez del sistema frente a adversidades. Los sistemas alternativos propuestos son:

- **E1 — Línea base:** Configuración actual con 10 camiones, asignación FIFO simple.
- **E2 — Tráfico pesado:** Escenario de estrés donde se fuerza `Traffic_Status = High` de forma global.
- **E3 — Demanda pico:** Escenario donde se duplica la tasa de llegadas esperada ($\lambda \times 2$).
- **E4 — Priorización climática:** Cambio de política de asignación para priorizar camiones climatizados basándose en los parámetros de `Temperature` y `Humidity`.
- **E5 — Configuración óptima:** Búsqueda del número c de recursos que satisface las restricciones de W_q y $P(\text{Delay})$.

3.4. Método de evaluación de alternativas

La efectividad de los sistemas alternativos se evaluará mediante la comparación estadística de las medias de W_q y ρ , así como la proporción de `Logistics_Delay`. Dado que el modelo de simulación es estocástico, se ejecutarán un mínimo de 30 réplicas independientes por cada escenario (E1 a E5). Esto garantizará la normalidad de los resultados mediante el Teorema del Límite Central, permitiendo construir intervalos de confianza para las cantidades de interés y asegurar que las decisiones tomadas tengan validez estadística.

4. Cronograma del proyecto

A continuación, se detallan las actividades planificadas para el desarrollo del estudio de simulación a lo largo del semestre académico, abarcando desde la formulación inicial hasta la sustentación de resultados.

Tabla 2: Cronograma de actividades del estudio de simulación 2026-1

Semana	Actividad
1–2 (mar)	Formulación del problema, revisión bibliográfica, selección y descarga del dataset logístico IoT.
3–4 (mar–abr)	Conceptualización del modelo, definición de variables, diseño del diagrama de flujo.
5–6 (abr)	Análisis exploratorio de datos en R y ajuste de distribuciones estadísticas de entrada.
20 (abr)	Implementación del prototipo de simulación discreta en Python (uso de librería SimPy).
1–2 (may)	Verificación lógica y validación del modelo base contra los datos históricos del dataset.
10–11 (may)	Ejecución de réplicas completas para los escenarios propuestos, análisis estadístico en R.
15 (may)	Comparación de escenarios alternativos, discusión de resultados y redacción de conclusiones.
25 (may)	Preparación de diapositivas y grabación del video de sustentación final.

5. Conceptualización del modelo

Notación

Símbolo	Significado	Valor (del dataset)
c	Número de camiones	10
$\lambda(t)$	Tasa de llegada a la hora t (pedidos/hora)	Variable (ver <code>tasas_por_hora.csv</code>)
$E[S]$	Tiempo medio de servicio (segundos)	Por calibrar
W_q	Tiempo de espera en cola (segundos)	Variable de salida
ρ	Utilización del sistema	Variable de salida
$P(\text{Delay})$	Probabilidad de retraso	Variable de salida

Tabla 3: Notación utilizada en el modelo de simulación.

Ecuaciones del modelo

1. Generación de llegadas (Poisson no estacionario)

El tiempo entre llegadas sigue una distribución exponencial cuya tasa depende de la hora del día:

$$T_{\text{llegada}} \sim \text{Exponencial} \left(\frac{\lambda(t)}{3600} \right)$$

Donde $\lambda(t)$ es la tasa en pedidos por hora para la hora t del día.

2. Tiempo de servicio (exponencial)

El tiempo que un camión permanece ocupado (carga + tránsito + descarga) se modela como:

$$S \sim \text{Exponencial} \left(\frac{1}{E[S]} \right)$$

La función de densidad de probabilidad es:

$$f_S(s) = \frac{1}{E[S]} e^{-s/E[S]}, \quad s \geq 0$$

3. Condición de estabilidad (Ley de Little)

Para que el sistema no colapse, la utilización promedio debe ser menor a 1:

$$\rho = \frac{\lambda \cdot E[S]}{c} < 1$$

Donde λ es la tasa media global de llegadas:

$$\lambda = \frac{1}{24} \sum_{t=0}^{23} \lambda(t)$$

Si $\rho \geq 1$, el sistema es inestable y la cola crece infinitamente.

4. Tiempo promedio de espera en cola (M/M/c con FIFO)

Para un sistema M/M/c con llegadas estacionarias, la fórmula de Erlang es:

$$E[W_q] = \frac{E[S] \cdot \rho}{c \cdot (1 - \rho)} \cdot \frac{(c\rho)^c}{c! \cdot \sum_{k=0}^{c-1} \frac{(c\rho)^k}{k!}}$$

Nota: Esta fórmula es para llegadas estacionarias. En nuestro caso se usa simulación debido a la no estacionariedad de $\lambda(t)$.

5. Métricas calculadas en simulación

Tiempo promedio de espera en cola:

$$\overline{W_q} = \frac{1}{n} \sum_{i=1}^n W_{q,i}$$

Donde $W_{q,i}$ es el tiempo que el pedido i esperó antes de ser asignado a un camión.

Utilización promedio de la flota:

$$\bar{\rho} = \frac{\sum_{j=1}^c \text{tiempo_ocupado}_j}{c \cdot T_{sim}}$$

Donde tiempo_ocupado_j es el tiempo total que el camión j estuvo atendiendo pedidos.

Probabilidad de retraso logístico:

$$P(\text{Delay}) = \frac{\#\{\text{pedidos con } W_q > \text{umbral}\}}{n}$$

6. Intervalo de confianza (Teorema del Límite Central)

Con $m = 30$ réplicas independientes, el intervalo de confianza al 95 % para cualquier métrica θ es:

$$IC_{95\%}(\theta) = \bar{\theta} \pm t_{0,025, m-1} \cdot \frac{\sigma_{\theta}}{\sqrt{m}}$$

Donde $t_{0,025, m-1}$ es el cuantil de la distribución t de Student con $m - 1$ grados de libertad.

5.1. Supuestos distribucionales del modelo

El modelo de simulación se basa en los siguientes supuestos distribucionales:

Llegadas (Poisson no estacionario)

Los tiempos entre llegadas de pedidos siguen una distribución exponencial, lo que equivale a un proceso de Poisson no estacionario con tasa $\lambda(t)$ variable por hora del día:

$$T_{\text{llegada}} \sim \text{Exponencial} \left(\frac{\lambda(t)}{3600} \right)$$

Este es el supuesto estándar para sistemas de colas con llegadas aleatorias e independientes

Tiempo de servicio

El tiempo que un camión permanece ocupado (carga + tránsito + descarga) sigue una distribución exponencial con media $E[S]$:

$$S \sim \text{Exponencial} \left(\frac{1}{E[S]} \right)$$

La función de densidad de probabilidad es:

$$f_S(s) = \frac{1}{E[S]} e^{-s/E[S]}, \quad s \geq 0$$

La elección de la distribución exponencial se justifica por:

1. Es el supuesto clásico del modelo M/M/c de teoría de colas
2. Posee la propiedad de falta de memoria, adecuada para sistemas donde la probabilidad de finalizar el servicio no depende del tiempo ya transcurrido
3. El dataset no contiene tiempos de servicio reales observados, por lo que se requiere un supuesto paramétrico
4. Simplifica el análisis y la calibración del modelo

Calibración del parámetro $E[S]$

Debido a la ausencia de tiempos de servicio reales en el dataset, el parámetro $E[S]$ se calibra indirectamente a partir de la Ley de Little utilizando:

- La utilización observada en el dataset: $\rho_{\text{obs}} = \overline{\text{Asset_Utilization}}/100$
- El número de camiones: $c = 10$
- La tasa global de llegadas: $\lambda = \frac{\# \text{ total llegadas}}{T_{\text{total}}} \text{ (pedidos/segundo)}$

Despejando de la ecuación de utilización:

$$\rho = \frac{\lambda \cdot E[S]}{c} \quad \Rightarrow \quad E[S] = \frac{\rho_{\text{obs}} \cdot c}{\lambda}$$

Limitaciones del supuesto

- La distribución exponencial tiene un coeficiente de variación igual a 1, lo que puede sobreestimar la variabilidad de los tiempos de servicio reales
- En operaciones logísticas reales, los tiempos de servicio suelen tener menor variabilidad (coeficiente de variación <1)
- Esta limitación debe tenerse en cuenta al interpretar los resultados, y se recomienda un análisis de sensibilidad variando la distribución asumida

Diagrama de Flujo del Algoritmo




Figura 1: Gráfica 1. Diagrama de simulación

Pseudocódigo

Algoritmo Simulación Logística

ALGORITMO SimulacionLogistica

INICIALIZAR:

```
t = 0
T_final = 168 * 3600  (1 semana en segundos)
c = 10  (número de camiones)
E[S] = tiempo_servicio_calibrado
cola = []
metricas = []
```

DECLARAR evento_llegada(env, pedido_id):

```
llegada_time = env.now
IF hay_camion_disponible():
    camion = asignar_camion()
    tiempo_espera = env.now - llegada_time
    registrar(tiempo_espera)
    IF tiempo_espera > UMBRAL:
        pedido.retrasado = True
    esperar(env, E[S])  (simular servicio)
    liberar(camion)
    IF cola NO está vacía:
        siguiente_pedido = cola.pop(0)
        procesar(siguiente_pedido)
ELSE:
    cola.append(pedido_id)
    registrar_inicio_espera(pedido_id, env.now)
```

DECLARAR generador_llegadas(env):

```
pedido_id = 0
WHILE True:
    hora_actual = (env.now // 3600) % 24
    tasa = tasa_llegada[hora_actual] / 3600  (pedidos/segundo)
    IF tasa > 0:
        intervalo = random.expovariate(tasa)
        wait(env, intervalo)
        pedido_id = pedido_id + 1
        Llamar evento_llegada(env, pedido_id)
    ELSE:
        wait(env, 3600)  (avanzar 1 hora)
```

PROCEDIMIENTO main():

```
env = crear_entorno()
env.process(generador_llegadas(env))
env.run(until=T_final)
```

Calcular:

```
Wq_promedio = mean(tiempos_espera)
P_delay = retrasados / total_pedidos
utilizacion = tiempo_total_ocupado / (c * T_final)
```

RETURN métricas

6. Recolección de Datos

Para la construcción y validación del modelo de simulación, se utilizó el dataset *Smart Logistics Supply Chain Dataset*, obtenido de Kaggle. Este conjunto de datos contiene 1000 registros históricos de operaciones logísticas, con 16 variables que capturan tanto el estado del sistema (niveles de inventario, estado de envíos) como las condiciones externas (tráfico, temperatura, humedad) que afectan el desempeño.

6.1. Variables relevantes para el modelo

A continuación se describen las variables del dataset que son directamente utilizadas en el modelo de simulación, así como su relación con los componentes del sistema modelado:

Tabla 4: Variables del dataset y su uso en el modelo

Variable	Tipo	Función en el modelo
Timestamp	Fecha-hora	Permite extraer la hora del día para calcular tasas de llegada $\lambda(t)$ no estacionarias
Asset_ID	Categórica (10 valores)	Identificador único de cada camión (recurso en SimPy)
Waiting_Time	Numérica (entero)	Variable de salida principal: tiempo de espera en cola W_q (segundos)
Asset_Utilization	Numérica (0-100)	Variable de salida: utilización de la flota ρ (%)
Traffic_Status	Categórica (Low/Medium/High)	Modifica los tiempos de tránsito en el modelo de servicio
Temperature	Numérica	Restricción ambiental para productos sensibles
Humidity	Numérica	Restricción ambiental para productos sensibles
Shipment_Status	Categórica (Delayed/In Transit/Delivered)	Variable de salida para verificar el estado final del envío
Logistics_Delay	Binaria (0/1)	Variable objetivo: $P(\text{Delay})$ a minimizar
Inventory_Level	Numérica	Restricción de disponibilidad de productos

6.2. Análisis exploratorio y visualizaciones

Con el fin de comprender las distribuciones subyacentes y las relaciones entre variables, se realizó un análisis exploratorio que incluyó 6 visualizaciones clave. A continuación se presentan y analizan

cada una de ellas.

1. Distribución del tiempo de espera observado




Figura 2: Histograma de la variable Waiting_Time

La Figura 2 muestra la distribución empírica de los tiempos de espera registrados en el dataset. Se observa una asimetría positiva (cola hacia la derecha), donde la mayoría de los pedidos experimentan tiempos de espera bajos (entre 0 y 20 segundos), pero existe una fracción no despreciable de pedidos con esperas superiores a 40 segundos. Esta forma sugiere que una distribución exponencial o log-normal podría ser adecuada para modelar este comportamiento. La media muestral se encuentra aproximadamente en 34 segundos, valor que servirá como referencia para la validación del modelo simulado.

2. Impacto del tráfico en el tiempo de espera




Figura 3: Diagrama de caja de Waiting_Time segmentado por Traffic_Status

La Figura 3 presenta la distribución del tiempo de espera según el nivel de congestión vehicular. Se evidencia un gradiente claro: a medida que el tráfico empeora (pasar de *Clear* a *Heavy*), el tiempo de espera esperado aumenta significativamente. En condiciones de tráfico intenso (*Heavy*), la mediana supera los 30 segundos y se presentan múltiples valores atípicos por encima de los 70 segundos. Este hallazgo justifica la inclusión del **Traffic_Status** como un factor modificador del tiempo de servicio en el modelo.

3. Volumen de llegadas por hora del día




Figura 4: Llegadas totales por hora del día

La Figura 4 revela la naturaleza no estacionaria del proceso de llegadas. Se identifican dos picos claros: uno en la mañana (horas 9–11) y otro más pronunciado en la tarde-noche (horas 15–21). Las horas de la madrugada (0–6) presentan muy baja actividad. Este patrón horario justifica el uso de una tasa de llegada $\lambda(t)$ variable en el tiempo, en lugar de un proceso Poisson estacionario.

4. Relación entre utilización de activos y tiempo de espera




Figura 5: Dispersión de Asset_Utilization vs Waiting_Time

La Figura 5 muestra la relación entre la utilización de los camiones y el tiempo de espera que experimentan los pedidos. Se observa una correlación positiva: a mayor utilización del activo, mayor es el tiempo de espera. Los puntos coloreados según `Logistics_Delay` indican que los retrasos se concentran en la región de alta utilización (por encima del 75 %) y altos tiempos de espera. Esta relación es consistente con la teoría de colas y valida la inclusión de ρ como métrica de estado.

5. Distribución de espera por estado de envío




Figura 6: Violinplot de `Waiting_Time` por `Shipment_Status`

La Figura 6 compara la distribución de los tiempos de espera entre los diferentes estados finales del envío. Los pedidos que resultan en *Delayed* presentan tiempos de espera sistemáticamente más altos (con una mediana alrededor de 52 segundos) en comparación con los entregados a tiempo (*Delivered*), cuyo tiempo de espera mediano es de aproximadamente 30 segundos. Los envíos en tránsito (*In Transit*) muestran una distribución intermedia. Este gráfico valida que la variable `Waiting_Time` es un predictor relevante del retraso logístico.

6. Mapa de calor de llegadas por hora y día de semana




Figura 7: Mapa de calor de llegadas (hora del día vs día de semana)

La Figura 7 presenta un análisis más detallado de la estacionalidad, cruzando la hora del día con el día de la semana. Se observa que los días de mayor actividad son los jueves, viernes y sábado (días 3, 4 y 5 en la codificación del gráfico), con picos consistentes en horas vespertinas. Esta información puede ser utilizada en versiones futuras del modelo para ajustar la tasa de llegada según combinación de hora y día.

6.3. Resumen de parámetros extraídos del dataset

A partir del análisis exploratorio y las visualizaciones, se extrajeron los siguientes parámetros que serán utilizados como entrada en el modelo de simulación:

Tabla 5: Parámetros calibrados a partir del dataset

Parámetro	Valor
Número de camiones (c)	10
Media de <code>Waiting_Time</code> observado	34 segundos
Percentil 80 de <code>Waiting_Time</code> (umbral de retraso)	42 segundos
Utilización media observada (ρ_{obs})	74.6 %
Días de datos analizados	5 días (lunes a viernes)
Temperatura media	22.4 °C
Humedad media	61.3 %

6.4. Relación entre los datos y el modelo de simulación

La siguiente tabla resume cómo cada variable del dataset se relaciona con los componentes del modelo de simulación implementado en SimPy:

Tabla 6: Mapeo de datos a componentes del modelo en SimPy

Variable del dataset	Componente del modelo	Implementación en SimPy
Timestamp	Tasa de llegada $\lambda(t)$	Parámetro variable en <code>random.expovariate()</code>
Asset_ID	Recurso (camiones)	<code>simpy.Resource(env, capacity=10)</code>
Waiting_Time	Variable de salida para validación	Comparación entre simulado y observado
Traffic_Status	Modificador de tiempo de servicio	Factor multiplicador en <code>env.timeout()</code>
Logistics_Delay	Variable objetivo	Umbral fijo del percentil 80 observado

Con base en estos datos y su análisis, el modelo de simulación queda calibrado para representar fielmente la dinámica estocástica del sistema real, permitiendo la evaluación de los escenarios alternativos propuestos en la Sección 3.

Referencias Bibliográficas

1. BANKS, J., CARSON, J.S., NELSON, B.L. y NICOL, D.M. *Discrete-event system simulation*. 5a edición. Pearson Educación, 2014.
2. LAW, A. M. *Simulation Modeling and Analysis*. 5th ed. McGraw-Hill, 2015.
3. MATHEW, S. et al. "IoT-enabled real-time simulation for smart logistics". *Winter Simulation Conference*, 2020.
4. SIMPY DEVELOPMENT TEAM. *SimPy: Discrete-Event Simulation for Python*. Disponible en: <https://simpy.readthedocs.io>
5. WICKHAM, H. *ggplot2: Elegant Graphics for Data Analysis*. Springer, 2016.
6. KAGGLE. *Smart Logistics Supply Chain Dataset*. Disponible en: <https://www.kaggle.com/datasets/ziya07/smart-logistics-supply-chain-dataset>